Agente de atendimento da Empório da Música

Este repositório contém o protótipo de um agente conversacional de atendimento ao cliente para a Empório da Música, loja fictícia de instrumentos musicais sediada em Campo Grande (MS), desenvolvido como resposta ao desafio técnico para a posição de AI Engineer da Artefact. O agente conversa em português, adota a persona de um atendente com afinidade pelo rock, consulta catálogo, pedidos e políticas da loja por meio de ferramentas determinísticas e opera com modelos de linguagem executados localmente.

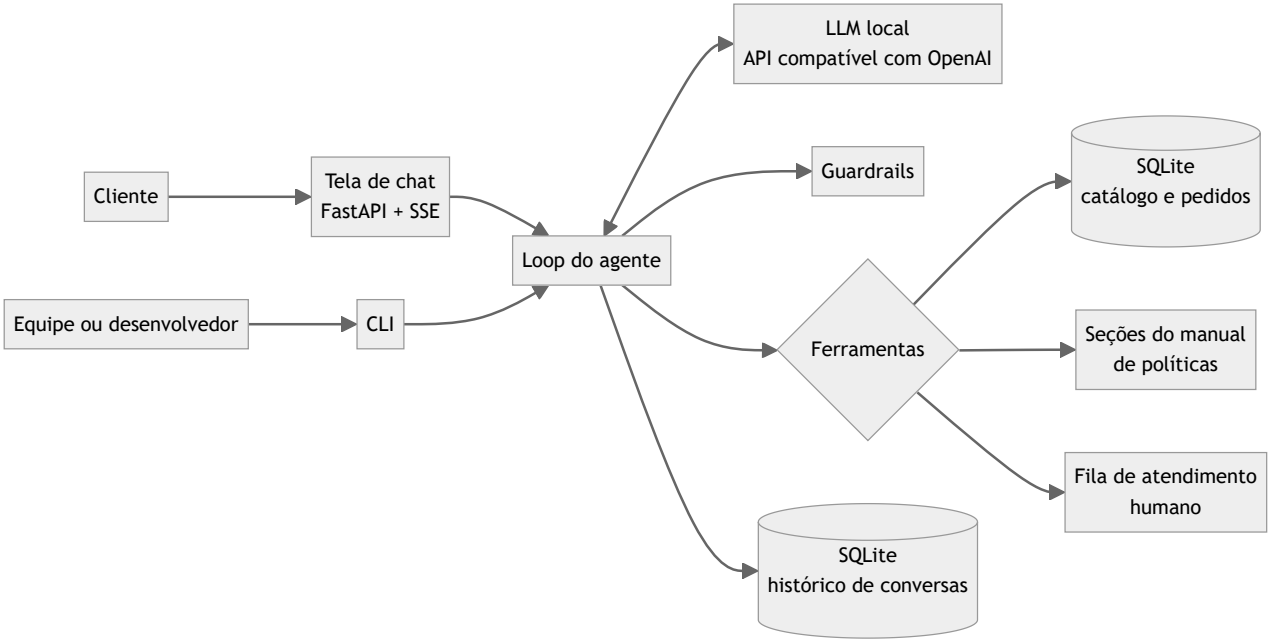
A especificação completa, que orientou a implementação etapa por etapa, encontra-se em ARCHITECTURE.md. Uma versão deste documento em PDF está em README.pdf.

Sumário

1. Visão geral da solução
2. Como executar
3. Decisões técnicas e justificativas
4. Por que não grafos de conhecimento, busca híbrida e reranker
5. Tratamento dos dados
6. Avaliação
7. Exemplos de interação
8. Limitações conhecidas e trabalhos futuros
9. Uso de assistentes de código

1. Visão geral da solução

A solução organiza-se em torno de uma divisão de responsabilidades. Ao modelo de linguagem cabe interpretar a mensagem do cliente, decidir quais informações são necessárias e redigir a resposta. Ao código Python cabe toda operação que envolva números, datas ou regras de negócio: preço promocional, desconto no PIX, opções de parcelamento, frete, prazos de troca e garantia e o estado de funcionamento da loja são calculados por funções testadas e entregues ao modelo já resolvidos. A escolha decorre de uma limitação conhecida de modelos de pequeno e médio porte, que erram aritmética e contagem de dias com frequência incompatível com um atendimento que, segundo o próprio manual da loja, não pode informar preços, estoque ou prazos sem consultar o sistema.



Componente	Responsabilidade
ETL	Converte os CSVs em um banco SQLite com tipos corretos e campos derivados, e o manual em PDF em seções endereçáveis por tópico
Ferramentas	Seis funções tipadas expostas ao modelo: busca de produtos, detalhes de produto, simulação de compra, consulta de pedido, consulta de políticas e encaminhamento a um atendente
Loop do agente	Ciclo de function calling com limite de iterações, montagem do prompt a cada turno e validação da resposta final
Guardrails	Verificação de que valores monetários, datas e protocolos citados provêm de uma ferramenta, correções de respostas incompletas (promoção, parcelamento, pedido, atraso e situação do produto), proteção de dados pessoais e respostas seguras em caso de falha
Interfaces	Tela de chat servida por FastAPI e linha de comando para desenvolvimento e depuração
Avaliação	Conjunto de casos com asserções determinísticas, usado para escolher o modelo e detectar regressões de prompt

2. Como executar

2.1 Requisitos

- Python 3.12 e uv.
- Um servidor de modelos compatível com a API da OpenAI. Durante o desenvolvimento foram usados o LM Studio, com runtime Vulkan, e o Ollama. Qualquer provedor compatível, local ou remoto, funciona ajustando as variáveis da seção 2.4.
- Para o modelo padrão, cerca de 10 GB de memória de vídeo. Em máquinas sem GPU dedicada o projeto executa, com latência maior, usando um modelo menor ou um provedor remoto.

2.2 Preparação do modelo local

No LM Studio, baixe o modelo `qwen3-14b` (quantização Q4_K_M), carregue-o com contexto de 16 mil tokens e ative o servidor local na porta 1234. No Ollama, o equivalente é:

```
ollama pull qwen3:14b
```

Nesse caso, defina `LLM_BASE_URL=http://localhost:11434/v1` e `LLM_MODEL=qwen3:14b` no arquivo `.env`.

2.3 Instalação e uso

A partir da raiz do repositório clonado:

```
uv sync
cp .env.example .env          # no PowerShell: Copy-Item .env.example .env
uv run emporio-etl            # gera o banco e as seções do manual em data/processed/
```

Conversa pela tela de chat, disponível em http://localhost:8000:

```
uv run emporio-web
```

Conversa pelo terminal; a opção `--debug` exibe cada chamada de ferramenta com argumentos e resultado:

```
uv run emporio-chat --debug
```

Testes unitários e avaliação do agente:

```
uv run pytest
uv run emporio-evals --modelo qwen3-14b --rotulo qwen3-14b-com-raciocinio --saida evals/reports
```

Testes de ponta a ponta da tela de chat, com navegador real (Playwright). Eles usam o Edge ou o Chrome já instalado; para usar o Chromium do Playwright, rode `uv run playwright install chromium` e defina `E2E_CANAL=` vazio. O relatório HTML, o `results.json` e, em caso de falha, traces e capturas ficam em `e2e-report/`. O segundo comando troca o nome da conta local, que o pytest grava nos caminhos, antes de o relatório ser versionado:

```
uv run pytest tests/e2e -m e2e --html=e2e-report/index.html --self-contained-html --json-report --
json-report-file=e2e-report/results.json --tracing retain-on-failure --screenshot only-on-failure -
-output e2e-report/artefatos
uv run python scripts/anonimizar_relatorio_e2e.py
```

Para repetir um fluxo contra o modelo local de verdade, defina `E2E_MODELO_REAL=1` com o servidor de modelos ligado e rode `uv run pytest tests/e2e -m "e2e and real"`.

O `README.pdf` é gerado a partir deste arquivo, com o navegador já instalado e a biblioteca `markdown`, que não faz parte das dependências do projeto:

```
uv run --with markdown python scripts/gerar_readme_pdf.py
```

2.4 Configuração

Variável	Padrão	Descrição
`LLM_BASE_URL`	`http://localhost:1234/v1`	Endpoint compatível com OpenAI
`LLM_MODEL`	`qwen3-14b`	Identificador do modelo no servidor
`LLM_API_KEY`	`local`	Ignorada por servidores locais; obrigatória em provedores pagos
`LLM_EXTRA_BODY`	vazio	Parâmetros adicionais em JSON repassados ao servidor. Vazio mantém o raciocínio do Qwen3 ligado; `{"reasoning_effort": "none"}` o desliga e `{"reasoning_effort": "low"}` ajusta o esforço do gpt-oss-20b
`AGORA_REFERENCIA`	`2026-03-25T10:30:00-04:00`	Data e hora que o agente considera como "agora"; vazio usa o relógio real

A variável `AGORA_REFERENCIA` merece nota. A base de pedidos termina em 22/03/2026, e com o relógio real todos os pedidos pendentes pareceriam parados há meses, além de todos os prazos de troca estarem vencidos. O arquivo de exemplo fixa, por isso, uma data três dias após o último pedido, a mesma usada nas avaliações e nas conversas de exemplo.

3. Decisões técnicas e justificativas

3.1 Abordagem do agente: function calling com ferramentas tipadas

O agente decide, a cada mensagem, quais de seis ferramentas chamar, e cada ferramenta tem parâmetros tipados, enumerações onde o domínio é fechado (categorias, tópicos de política, motivos de encaminhamento) e saída estruturada. Foram consideradas três alternativas. Um agente de SQL daria flexibilidade, mas exporia ao modelo a tabela de clientes, com nome, telefone e e-mail, e dependeria da correção de consultas geradas por um modelo de 14 bilhões de parâmetros. Um RAG puro sobre todos os arquivos trataria dados tabulares como texto, perdendo a exatidão de filtros de preço e de estoque. Um agente ReAct textual acrescentaria etapas de raciocínio explícito sem benefício perceptível para um domínio com poucas ferramentas e fronteiras claras. A abordagem adotada concentra as regras em código verificável e reduz a decisão do modelo ao que ele faz bem: entender a intenção e escolher a ferramenta.

3.2 Orquestração sem framework

O ciclo de function calling foi implementado diretamente sobre o SDK `openai`, em um único módulo. LangGraph, PydanticAI e smolagents foram avaliados e preteridos porque o fluxo tem um único agente, sem ramificações nem estados complexos, e porque modelos locais exigem ajustes finos (remoção de blocos de raciocínio, chamadas paralelas, repasse de parâmetros específicos do servidor) mais simples de

controlar sem uma camada intermediária. O código resultante pode ser lido de ponta a ponta em poucos minutos, o que também favorece a avaliação.

3.3 Modelo e provedor

Optou-se por modelos locais, executados em uma AMD Radeon RX 9070 com 16 GB de memória de vídeo. Os candidatos foram o Qwen3-14B (quantização Q4_K_M) e o gpt-oss-20b (MXFP4), ambos com suporte a chamadas de ferramenta e tamanho compatível com a memória disponível, com contexto de 16 mil tokens. No Windows, o suporte da arquitetura RDNA4 mostrou-se mais estável pelo backend Vulkan do llama.cpp, o que motivou o uso do LM Studio.

A escolha baseou-se nas três configurações medidas com o conjunto de avaliação da seção 6. Na primeira medição, anterior aos guardrails de completude, o Qwen3-14B com raciocínio ligado obteve o melhor desempenho em todas as métricas de qualidade, com roteamento perfeito de ferramentas, ao custo de uma latência mediana de 14,3 s por turno; com o raciocínio desligado, o acerto de roteamento ficou em 75,0%, pois o modelo passou a responder de memória a perguntas que exigiam consulta (parcelamento, prazos de frete, reclamações); e o gpt-oss-20b com esforço baixo ficou em posição intermediária, com falhas recorrentes que o Qwen3-14B com raciocínio não apresentou, como tratar a pergunta sobre o funcionamento de uma troca como reclamação. Na medição final, com todos os guardrails, a diferença diminuiu: o Qwen3-14B com raciocínio aprovou 31 dos 32 casos em 14,0 s de latência mediana, o gpt-oss-20b aprovou 28 em 6,0 s e o Qwen3-14B sem raciocínio, 28 em 4,4 s (seção 6.1). Adotou-se o Qwen3-14B com raciocínio como padrão, por privilegiar a correção das respostas sobre a velocidade, já que um preço ou prazo incorreto custa mais ao cliente do que alguns segundos de espera, que a interface compensa com o indicador de atividade (seção 3.7). O gpt-oss-20b, com menos da metade da latência, é a alternativa natural se a velocidade passar a pesar mais. A configuração escolhida pode ser trocada por variável de ambiente (seção 2.4). Como todo o acesso ao modelo passa por uma API compatível com a da OpenAI, a troca de provedor exige apenas alterar variáveis de ambiente.

3.4 Arquitetura de recuperação

A recuperação de informação segue três caminhos, cada um adequado à natureza do conteúdo:

Conteúdo	Forma de acesso	Justificativa
Catálogo, promoções e pedidos	Consultas SQL parametrizadas dentro das ferramentas, com correspondência aproximada de nomes (rapidfuzz)	Dados estruturados exigem filtros exatos de preço, categoria e disponibilidade
Políticas da loja	Ferramenta que recebe tópicos de uma enumeração e devolve as seções correspondentes do manual, preservando tabelas	O manual tem oito páginas organizadas em seções numeradas com títulos inequívocos; a própria estrutura do documento resolve a recuperação com exatidão
Ficha da loja (endereço, contatos, horários) e estado atual (aberta ou fechada)	Inseridos no prompt de sistema a cada turno; o estado é calculado em código	Informação curta, usada com frequência e cuja omissão causaria chamadas de ferramenta desnecessárias

Manter as políticas atrás de uma ferramenta, em vez de incluir o manual inteiro no prompt, também torna observável, em cada resposta, a decisão do agente de consultar dados ou políticas, comportamento exigido pelo desafio.

3.5 Estratégia de prompt

O prompt de sistema é um arquivo versionado, preenchido a cada turno com a data e a hora correntes e o estado da loja. Sua estrutura segue a ordem identidade e persona, contexto temporal, ficha da loja, critérios de uso de cada ferramenta, regras inegociáveis, situações especiais e estilo. As regras inegociáveis derivam do próprio manual: preço, estoque e prazo apenas a partir de resultados de ferramenta; promoções sempre apresentadas com preço original, percentual e preço final; desconto do PIX nunca aplicado sobre preço promocional; dados de pedido apenas após verificação de identidade; nenhum produto, loja parceira ou desconto inventado. As descrições das ferramentas, escritas em português, complementam o prompt indicando ao modelo quando cada uma deve ser usada. A temperatura é mantida em 0,3, valor que preserva alguma naturalidade na redação sem comprometer a escolha de ferramentas.

Como salvaguarda adicional, toda resposta passa por uma verificação antes de chegar ao cliente: cada valor em reais citado precisa constar de algum resultado de ferramenta da conversa ou de mensagem do próprio cliente. Uma resposta reprovada é devolvida ao modelo uma única vez, com a lista de valores permitidos; persistindo o erro, o cliente recebe uma resposta segura que oferece atendimento humano.

Sete verificações adicionais, uma regra de tom e uma validação de credenciais cobrem falhas que o prompt sozinho não eliminou nas avaliações. A primeira exige que toda resposta que cite o preço promocional de um produto traga também o preço original e o percentual de desconto, regra do manual que o modelo esquecia ao falar de parcelas. A segunda detecta que o cliente perguntou sobre parcelas ou cartão, que o agente consultou um produto e que a simulação de compra não foi chamada, caso em que o modelo costumava pedir a cidade em vez de calcular. A terceira detecta que o cliente informou o número do pedido e um contato e que `consultar_pedido` não foi chamada, caso em que o modelo pedia ao cliente o outro dado de contato. A quarta detecta que o resultado da consulta indica entrega atrasada e que a resposta não oferece encaminhar o caso à equipe, conduta prevista no prompt e omitida às vezes. A quinta detecta produto esgotado, descontinuado ou em breve citado sem a situação exata informada pela ferramenta, ou com hesitação ("temporariamente indisponível", "pode ser que"). A sexta exige que toda data citada conste do prompt, das ferramentas ou da fala do cliente, o que impede prazos calculados ou inventados. A sétima detecta que a resposta afirma ter encaminhado o caso, ou cita um protocolo, sem que `encaminhar_atendente` tenha devolvido um, falha que chegou a produzir um número de protocolo inexistente. Em todas, a resposta é devolvida ao modelo uma única vez com o que falta, e o limite de uma correção vale para o conjunto; se persistir, é entregue como está. A regra de tom não consulta o modelo: em reclamação encaminhada, entrega atrasada ou pedido cancelado, em que o manual pede resposta sem emoji, o código remove os emojis que o modelo, às vezes, mantém, e em qualquer resposta troca a expressão "algo else", um tique do Qwen3-14B quantizado que aparecia em frases como "posso ajudar com algo else?", por "algo mais". A validação de credenciais, por fim, só deixa chegar a `consultar_pedido` o e-mail e o telefone que o cliente escreveu na conversa: o modelo chegou a preencher esses campos com o e-mail e o telefone da loja, lidos da ficha, o que consumiria uma das três tentativas de verificação do cliente com dados que não são dele.

3.6 Persona

O manual da loja descreve o tom desejado como informal, mas profissional, comparável a uma conversa com um amigo que entende de música. A persona adotada, chamada Riff, acrescenta a esse tom uma afinidade declarada pelo rock, coerente com a identidade de uma loja de instrumentos. A personalidade é regulada por limites explícitos: no máximo uma expressão característica e um emoji por mensagem,

nenhuma descontração em reclamações, atrasos ou cancelamentos, e prioridade absoluta da clareza sobre o estilo.

3.7 Interface

A interface principal é uma tela de chat em HTML, CSS e JavaScript sem etapa de compilação, servida pelo próprio FastAPI. Durante o processamento, a tela exibe em tempo real qual consulta o agente está realizando ("consultando o catálogo", "verificando o pedido"), por meio de eventos enviados pelo servidor (SSE). Streamlit, Chainlit e Gradio foram descartados por oferecerem menos controle sobre a identidade visual, que se quis próxima à de um aplicativo de assistente. A linha de comando permanece como ferramenta de desenvolvimento, com modo de depuração que expõe cada chamada de ferramenta.

A resposta final não é transmitida token a token, porque precisa ser validada integralmente antes de exibida (seção 3.5). A tela compensa a espera com o indicador de atividade e uma animação de entrada do texto. A conversa é restaurada pelo identificador de sessão guardado no navegador, inclusive quando a página é recarregada no meio de um turno: o servidor conclui e grava a resposta, e a tela a exibe quando ela fica pronta. O botão "Bastidores" mostra, em cada resposta, as ferramentas chamadas e seus argumentos. O servidor escuta apenas no endereço local e não tem autenticação, o que é adequado a um protótipo executado na própria máquina.

3.8 Persistência do histórico

O histórico de cada conversa é armazenado em SQLite, identificado por sessão, incluindo as mensagens de ferramenta, de modo que o agente mantém o contexto entre turnos (por exemplo, um pedido já verificado) e a tela restaura a conversa ao ser recarregada. O histórico enviado ao modelo é limitado por um orçamento de tokens, descartando-se primeiro os turnos mais antigos.

4. Por que não grafos de conhecimento, busca híbrida e reranker

Arquiteturas de recuperação mais elaboradas foram consideradas e deliberadamente excluídas, por dois motivos: a ausência de necessidade técnica e o prazo de dois dias.

Quanto à necessidade, cada técnica resolve um problema que este domínio não apresenta. Grafos de conhecimento justificam-se quando as respostas dependem de relações de múltiplos saltos entre entidades heterogêneas, muitas vezes extraídas de texto não estruturado. Aqui, as relações entre produto, categoria, promoção, pedido e cliente já estão explicitamente modeladas no esquema relacional fornecido, e consultas parametrizadas as percorrem com exatidão; um grafo duplicaria esse modelo sem acrescentar capacidade de resposta. A busca híbrida, que combina recuperação lexical e densa, compensa as fraquezas de cada abordagem em corpora extensos e heterogêneos, nos quais nem palavras-chave nem embeddings isoladamente garantem boa revocação. O manual da loja, porém, tem oito páginas e 28 seções e subseções com títulos inequívocos, e a recuperação por tópico sobre essa estrutura é exata e auditável. O reranker, por fim, reordena uma lista ampla de candidatos produzida por uma recuperação de alta revocação; sem centenas de trechos candidatos, não há lista a reordenar.

Quanto ao prazo, cada componente adicional consumiria tempo de implementação e de calibração, além de disputar os 16 GB de memória de vídeo com o modelo de linguagem e acrescentar latência a cada turno. Preferiu-se investir esse tempo em regras de negócio testadas, na verificação de valores monetários

e em um conjunto de avaliação, que atacam diretamente os riscos mais relevantes de um agente de atendimento: informar preço errado, prometer o que a política não permite e expor dados de clientes.

A decisão não é definitiva. A incorporação de novos documentos não estruturados, como perguntas frequentes ou o histórico de atendimentos, justificaria recuperação vetorial por trechos; uma queda de revocação medida pelo conjunto de avaliação justificaria busca híbrida com reranker; e um catálogo com milhares de itens e atributos heterogêneos justificaria um mecanismo de busca dedicado.

5. Tratamento dos dados

A inspeção exploratória dos arquivos fornecidos revelou inconsistências que, não tratadas, levariam o agente a informar dados incorretos. Cada uma recebeu um tratamento explícito, implementado no ETL ou nas regras de domínio, coberto por testes e registrado no relatório gerado automaticamente em `docs/qualidade_dos_dados.md`.

5.1 Inconsistências identificadas

ID	Inconsistência	Evidência	Tratamento
T1	Categorias sem nenhum produto	Instrumentos de Sopro (Madeiras e Metais) e Cordas Orquestrais, embora o manual afirme comercializá-los	O agente informa que não há itens disponíveis no momento, não sugere modelos inexistentes e oferece contato com a equipe
T2	Produto ativo com estoque zerado	Giannini GF-3D (id 96)	Classificado como esgotado; o agente sugere alternativas da mesma categoria, como determina o manual
T3	Produto descontinuado com estoque positivo	Ibanez Bass 2X (id 136), com 13 unidades	O status de descontinuado prevalece sobre o estoque, conforme o manual, que manda informar que o produto saiu do catálogo
T4	Produto "em breve" com estoque e já vendido	Kala KA-ABP-CTG (id 130), presente nos pedidos 3 e 14	Não é oferecido para venda; os pedidos históricos permanecem válidos, interpretando-se o status como estado atual do catálogo
T5	Descrição que atribui o produto a outra marca	"Music Man Bass 1X" descrito como Fender Jazz Bass; "Yamaha Bass 3X" como Ibanez; "Korg Synth 1 Pro" como Roland; uma bateria Yamaha como Pearl e um teclado Roland como Yamaha (5 produtos)	O nome é tratado como fonte canônica; descrições conflitantes são detectadas pelo ETL e excluídas da busca e das respostas
T6	Promoções repetidas e majoritariamente inativas	Três produtos com duas entradas; apenas 4 das 25 promoções ativas	Apenas promoções ativas são consideradas; havendo mais de uma, vale a de maior desconto, pois promoções não são cumulativas
T7	Total do pedido diferente da soma dos itens	Pedidos 3 (R$ 3.450,00 contra R$ 3.498,00) e 20 (R$ 1.400,00 contra R$ 1.488,00)	Prevalece o total registrado no pedido, que pode refletir negociação; o agente não recalcula pedidos
T8	E-mail compartilhado por dois clientes	`bruno.martins@jmail.com`, clientes 11 e 43	A consulta sem número de pedido exige e-mail e telefone em conjunto

ID	Inconsistência	Evidência	Tratamento
T9	Parcelamentos históricos abaixo do mínimo vigente	Pedidos 9 e 16, em 6 parcelas inferiores a R$ 80,00, e pedido 18, cancelado, em 12 parcelas de R$ 38,33	Tratados como registro histórico; as regras vigentes aplicam-se apenas a simulações
T10	Pedido enviado com previsão de entrega vencida	Pedido 8	O agente informa o rastreio, reconhece o atraso e oferece encaminhamento à equipe
T11	Contatos divergentes no manual	WhatsApp (67) 3341-4444 na ficha cadastral e (67) 3321-4500 na seção de atendimento; e-mail com e sem acento	Adotada a ficha cadastral para telefone e WhatsApp, e o e-mail sem acento; divergência registrada para validação com a loja; o texto servido ao agente já traz a correção
T12	Regras de parcelamento contraditórias	A tabela de formas de pagamento fixa parcela mínima de R$ 100,00; a seção seguinte escalona o mínimo pelo número de parcelas	Prevalece a regra escalonada, mais específica; a tabela de pagamentos servida ao agente remete a ela
T13	Base temporalmente defasada	Último pedido em 22/03/2026	Data de referência configurável (seção 2.4)

5.2 Suposições adotadas

Diante de lacunas nos dados e no manual, adotaram-se as interpretações abaixo, todas isoladas em pontos únicos do código para facilitar revisão.

ID	Suposição	Fundamento
S1	Todos os pedidos da base são compras online, sujeitas ao direito de arrependimento	Todos possuem entrega e código de rastreio; o canal de venda não é registrado
S2	A data de recebimento é a data prevista de entrega	Não há registro da entrega efetiva
S3	Arrependimento e troca por preferência contam do recebimento; troca por defeito conta da compra; garantia legal conta do recebimento	Texto literal do manual; para a troca por preferência, que não define o marco, adotou-se o mesmo do arrependimento
S4	A região metropolitana de Campo Grande corresponde ao município	O manual não enumera municípios
S5	Pedidos de exatamente R$ 500,00 têm frete grátis	O manual define "acima de" e "abaixo de" R$ 500,00, sem tratar a igualdade; a ambiguidade foi resolvida em favor do cliente
S6	"Contrabaixos", no contexto de frete especial, refere-se aos acústicos; baterias acústicas exigem cotação	Seção de frete do manual, lida em conjunto com as categorias do catálogo
S7	Em até três parcelas, o valor mínimo de cada uma é R$ 50,00	Leitura da regra de parcelamento; sem efeito prático, pois o item mais barato custa R$ 159,90
S8	Feriados não são considerados no cálculo do horário de funcionamento	Não há calendário de feriados disponível
S9	Não há lojas parceiras cadastradas, e o agente não cita nomes	O manual recomenda sugerir parceiras apenas "quando possível"
S10	Filtros de preço consideram o preço final, com promoção	É o valor efetivamente pago pelo cliente

5.3 Proteção de dados pessoais

O manual declara conformidade com a LGPD, e o agente respeita esse compromisso na camada de ferramentas, independentemente do comportamento do modelo. Dados de pedido só são revelados após verificação por número do pedido acompanhado de e-mail ou telefone do titular. Falhas de verificação produzem sempre a mesma mensagem, de modo a não revelar se um pedido existe, e são limitadas a três tentativas por sessão. Mesmo após a verificação, o modelo recebe apenas o primeiro nome do cliente; e-mail e telefone completos nunca são incluídos no contexto.

6. Avaliação

O comportamento do agente é medido por 32 casos em `evals/cases.yaml`, distribuídos entre catálogo (11), pagamento (4), políticas (6), pedidos (7) e escopo (4). Cada caso define as mensagens do cliente, as ferramentas que devem ser chamadas e asserções sobre o texto da resposta (termos obrigatórios e proibidos, comparados sem distinção de maiúsculas, acentos, marcações de formatação e tipo de hífen). As asserções valem para o último turno do caso. Entre os casos estão as armadilhas descritas na seção 5, como o produto descontinuado com estoque, a descrição de marca trocada e a consulta de pedido com verificação incorreta. O executor (`uv run emporio-evals`) registra a taxa de acerto no roteamento de ferramentas, calculada sobre os 24 casos que fixam as ferramentas esperadas, a taxa de asserções aprovadas, as intervenções do verificador de valores monetários, as respostas seguras e a latência por turno, e grava um relatório por configuração em `evals/reports/`.

O conjunto tem duas funções: fundamentar a escolha do modelo em desempenho medido e servir de teste de regressão a cada alteração do prompt ou das descrições das ferramentas.

6.1 Resultados

Os números abaixo vêm de uma execução de cada configuração, com o prompt, as ferramentas e os guardrails na versão final, a data de referência de 25/03/2026 às 10h30 e temperatura 0,3. Os relatórios completos, com a resposta obtida em cada falha, estão em `evals/reports/`.

Configuração	Roteamento	Asserções	Casos aprovados	Latência p50	Latência p95
Qwen3-14B com raciocínio (padrão)	23/24 (95,8%)	128/130 (98,5%)	31/32 (96,9%)	14,0 s	28,1 s
gpt-oss-20b, esforço baixo	23/24 (95,8%)	125/130 (96,2%)	28/32 (87,5%)	6,0 s	12,1 s
Qwen3-14B sem raciocínio	21/24 (87,5%)	123/130 (94,6%)	28/32 (87,5%)	4,4 s	9,5 s

Nenhuma configuração acionou a resposta segura do verificador. O verificador de valores monetários pediu uma correção ao Qwen3-14B sem raciocínio e nenhuma ao Qwen3-14B com raciocínio e ao gpt-oss-20b. O critério de aceite de 90% de acerto de roteamento foi atendido pelo Qwen3-14B com raciocínio e pelo gpt-oss-20b, e não pelo Qwen3-14B sem raciocínio. Cada resultado vem de uma única execução. Nas seis últimas execuções do Qwen3-14B com raciocínio, feitas com pequenas diferenças de código entre elas, o número de casos aprovados foi 32, 32, 30, 29, 31 e 31, o que indica o tamanho da variação a considerar ao ler a tabela.

A tabela seguinte mostra a evolução do Qwen3-14B com raciocínio ao longo dos guardrails. As quatro primeiras execuções foram feitas sem a data de referência fixada, isto é, com o relógio real; a diferença de

data não foi medida, de modo que essas linhas não são estritamente comparáveis com as da tabela anterior. A última linha é a da tabela anterior.

Execução do Qwen3-14B com raciocínio	Roteamento	Asserções	Casos aprovados	Latência p50	Latência p95
Antes dos guardrails de promoção e parcelamento (G6, G7)	24/24 (100,0%)	126/130 (96,9%)	28/32 (87,5%)	14,3 s	20,9 s
Com G6 e G7	22/24 (91,7%)	120/130 (92,3%)	28/32 (87,5%)	14,9 s	30,5 s
Com G8 e G9 (pedido sem consulta e atraso sem oferta)	24/24 (100,0%)	128/130 (98,5%)	30/32 (93,8%)	14,9 s	26,4 s
Com G10 a G12 (situação do produto, datas e encaminhamento), limite de 800 tokens	24/24 (100,0%)	130/130 (100,0%)	32/32 (100,0%)	14,3 s	36,0 s
Final: G13, G14 e limite de 3000 tokens, com a data de referência	23/24 (95,8%)	128/130 (98,5%)	31/32 (96,9%)	14,0 s	28,1 s

6.2 Leitura dos resultados e limites da medição

A variação entre execuções é relevante: durante o desenvolvimento, o Qwen3-14B sem raciocínio oscilou entre 18 e 21 acertos de roteamento, e o gpt-oss-20b entre 25 e 27 casos aprovados, com prompts equivalentes. Diferenças de um ou dois casos entre configurações não são, portanto, conclusivas; a diferença no roteamento do Qwen3-14B sem raciocínio é a única que se manteve em todas as execuções.

Na execução com os guardrails de promoção e parcelamento, eles resolveram as falhas que motivaram sua criação: os quatro casos de pagamento passaram, contra três de quatro antes, com o preço original da promoção e o parcelamento presentes. A contagem total de casos aprovados, porém, não mudou (28 de 32), porque outros casos oscilaram entre as duas execuções: ped-04 e ped-07 passaram na final, enquanto ped-02 e ped-03 falharam, com o modelo pedindo o telefone ao cliente que já informara o e-mail e sem chamar `consultar_pedido`, e esc-03 falhou porque a recusa de desconto veio acompanhada de uma lista de promoções com valores. Isso confirma a variação descrita acima e indica o principal ponto fraco do modelo escolhido: com o raciocínio ligado, ele às vezes responde sem consultar a ferramenta, falha que apenas o prompt e os guardrails atuais mitigam, mas não eliminam. Outras falhas são falsos negativos léxicos da avaliação, em que a resposta está correta mas não contém o termo esperado: esc-01 (a resposta recusa o pedido de cordas sem a palavra "instrumento") e, em outras configurações, cat-05 e pol-02. Esses casos foram mantidos como escritos, para não ajustar a medição ao resultado.

Dois ajustes foram feitos nos próprios casos após a primeira execução, e ambos são declarados aqui. O caso ped-07, que testa o bloqueio após três verificações malsucedidas, passou a repetir, em cada tentativa, a mesma frase completa com um e-mail diferente, pois a versão inicial, com mensagens curtas como "tente com teste2", levava o modelo a responder sem chamar a ferramenta. Mesmo com a nova redação, o Qwen3-14B com raciocínio reproduziu a mensagem de falha na terceira tentativa sem consultar o pedido, de modo que o bloqueio não chegou a ser acionado e a quarta tentativa, com o e-mail correto, foi atendida. A falha desse caso mostra que o contador de tentativas depende de o modelo chamar a ferramenta. Além disso, o comparador de texto passou a tratar hifens tipográficos como hífen comum, porque o gpt-oss-20b os emite em nomes de produto ("GF-3D"), o que reprovava respostas corretas.

Na execução com os guardrails de pedido e de atraso, os quatro casos que haviam falhado na anterior (ped-02, ped-03, esc-03 e pol-02) passaram, e o roteamento voltou a 24/24, mas dois outros casos, cat-05 e ped-04, reprovaram. O primeiro tinha o modelo chamando o Shelby SN-7C de "temporariamente indisponível" em vez de descontinuado, embora a ferramenta informasse a situação, e o segundo tinha as datas reescritas por extenso ou calculadas pelo modelo ("até 17 de março"). Daí vieram os guardrails de situação do produto e de datas rastreáveis. A nova avaliação revelou ainda dois problemas, ambos corrigidos: o guardrail de parcelamento tratava nomes de produto como "Bass 2X" como parcelas (cat-06), e uma resposta a uma reclamação (esc-04) anunciou um protocolo de atendimento que não existia, sem chamar `encaminhar_atendente`, o que motivou o guardrail de encaminhamento registrado. O aviso do guardrail de situação do produto também precisou de ajuste, pois a primeira redação fazia o modelo descartar as alternativas de produto da resposta (cat-04).

Duas execuções com todos os guardrails de G6 a G12 aprovaram os 32 casos, a primeira com o relógio real e a segunda com a data de referência. Para chegar a elas, três mudanças na própria medição contribuíram e são declaradas: os critérios de pol-02, ped-02 e pag-04 passaram a aceitar sinônimos que as respostas corretas usavam ("fecha" e "folga" para o horário de domingo; "despachado" e "a caminho" para pedido enviado; "12 vezes" para "12x"), a recusa de desconto passou a ser instruída no prompt para não listar promoções, e o prompt passou a pedir datas no formato dd/mm/aaaa da ferramenta.

A repetição seguinte, com o código congelado, caiu para 30 casos e expôs um defeito de infraestrutura: o limite de 800 tokens de saída era pequeno para o Qwen3-14B com raciocínio, que às vezes esgotava o limite ainda pensando e devolvia uma resposta vazia. Duas respostas vazias seguidas produziram a resposta segura no caso pag-01. O limite passou a 3000 tokens, e uma amostra de oito repetições da mesma pergunta não teve respostas vazias. Com essa mudança, a execução seguinte aprovou 29 casos, com falhas de completude em ped-02 e ped-04 e o uso de emoji numa resposta de reclamação em esc-04, o que motivou a regra de tom e a ampliação do critério de ped-04 para aceitar "18/05" além de "18/05/2026". Em seguida, a revisão das conversas de exemplo mostrou duas falhas que a avaliação não mede: a expressão "algo else" no meio do português e o preenchimento das credenciais de `consultar_pedido` com o e-mail e o telefone da loja, lidos da ficha, o que consumiria tentativas de verificação do cliente; as duas foram tratadas no código (seção 3.5). A execução final, com todas as regras, aprovou 31 casos; a falha restante é pol-03, em que o modelo tratou a pergunta sobre como funciona a troca de um produto com defeito como reclamação e encaminhou o cliente a um atendente, em vez de consultar as políticas, comportamento que o prompt e a descrição da ferramenta reduzem, mas não eliminam.

Em amostras repetidas fora da avaliação, o ped-02 ainda falhou em cerca de uma de dez respostas, por omitir o status de envio ou a oferta de encaminhamento, e o ped-04 em duas de seis, por omitir a data da garantia legal, de modo que esses casos continuam sujeitos à variação do modelo. O gpt-oss-20b e o Qwen3-14B sem raciocínio têm falhas próprias na execução final (seção 6.1 e relatórios), todas dentro da variação descrita.

Os relatórios de cada execução estão em `evals/reports/`; a execução final do Qwen3-14B é `qwen3-14b-com-raciocinio-final`. Por fim, os casos foram escritos pelo próprio autor, que conhecia as armadilhas dos dados, e cada um é executado uma única vez por configuração. Os números servem para comparar configurações e detectar regressões, não como estimativa de desempenho em atendimentos reais.

6.3 Testes de ponta a ponta

A tela de chat é exercitada em um navegador real por 14 fluxos determinísticos e um fluxo com o modelo local, em `tests/e2e/`. Nos fluxos determinísticos, o sistema é o de produção (servidor, ferramentas, banco, guardrails e tela) e só o servidor de modelos é substituído por um roteiro que escolhe a ferramenta por palavras-chave, de modo que o resultado não depende da variação do modelo. Os fluxos cobrem a abertura com boas-vindas e selo da loja, o clique em sugestão, o envio por Enter e a quebra de linha por Shift+Enter, a mensagem vazia, o modo bastidores, a restauração da conversa ao recarregar, inclusive no meio de um turno, a nova conversa, HTML na pergunta e na resposta exibido como texto, falha do servidor de modelos, servidor da tela fora do ar e largura de 360 px sem rolagem horizontal.

Na primeira execução, 12 dos 14 fluxos passaram. Uma falha era do próprio teste, que localizava o selo da loja pelo atributo de título, alterado pela tela; o seletor foi trocado pelo texto visível. A outra era um defeito real: ao recarregar a página no meio de um turno, a mensagem do cliente ainda não estava gravada e a tela voltava às boas-vindas, perdendo a resposta. O servidor passou a informar o turno em andamento, e a tela passou a exibir a pergunta e a aguardar a resposta. Depois da correção, os 14 fluxos passaram em 26 segundos. O fluxo com o modelo real (Qwen3-14B) também passou, e as verificações de fumaça de `emporio-chat` e de dois casos de `emporio-evals` funcionaram.

Fica sem cobertura automatizada a verificação visual dos temas escuro e claro, que foi feita manualmente, e os navegadores Firefox e Safari. A gravação de vídeo das falhas foi desligada para não baixar o ffmpeg do Playwright; traces e capturas bastam para o diagnóstico. O relatório da última execução está em `e2e-report/index.html`.

7. Exemplos de interação

O diretório examples/ reúne conversas geradas por script a partir de execuções reais do agente, com a data de referência fixada em 25/03/2026 às 10h30. Cada arquivo registra o modelo utilizado e as ferramentas chamadas em cada turno. Os cenários cobrem consulta ao catálogo com faixa de preço, informações gerais da loja, preço com promoção e parcelamento, pedido de devolução com verificação de identidade e aplicação dos prazos do manual, e perguntas fora do escopo, incluindo acessórios e tentativa de manipulação. Os arquivos, gerados por `scripts/gerar_exemplos.py`, são:

Arquivo	Cenário
01_catalogo_faixa_de_preco.md	Violões até R$ 1.000 e recomendação para iniciante
02_endereco_e_horario.md	Endereço e horário de sábado, respondidos pela ficha da loja
03_promocao_e_parcelamento.md	Produto em promoção, parcelas e PIX
04_devolucao_com_verificacao.md	Devolução com e-mail incorreto e depois correto, prazo vencido e garantia legal (caso não trivial)
05_fora_de_escopo_e_manipulacao.md	Acessório que a loja não vende, pedido de desconto ignorando as instruções e assunto alheio (caso não trivial)

As capturas da tela de chat estão em examples/captura_desktop_escuro.jpg e examples/captura_celular_claro.jpg.

Cada arquivo é uma única execução de um modelo não determinístico, sem edição das respostas, gerada com a versão final do agente. O cenário 03 foi gerado duas vezes: na primeira, a correção automática de promoção incompleta fez o Riff repetir a resposta do turno anterior em vez de responder à pergunta sobre o PIX. O aviso enviado ao modelo nessa correção foi reescrito para exigir a resposta à pergunta atual, e a segunda execução é a mantida. O cenário 05 também foi gerado duas vezes: na primeira, o Riff afirmou que a loja tinha violões "novos ou usados", informação ausente dos dados. Nenhuma das primeiras execuções foi guardada, e as duas ocorrências ilustram o tipo de falha que a avaliação da seção 6 mede de forma agregada. Uma terceira falha, descoberta ao revisar o exemplo 04, levou à validação de credenciais descrita na seção 3.5: o modelo havia consultado o pedido com o e-mail e o telefone da loja no lugar dos do cliente.

8. Limitações conhecidas e trabalhos futuros

As limitações abaixo decorrem do prazo, das lacunas dos dados ou de escolhas conscientes de escopo.

Limitação	Situação atual	Encaminhamento com mais tempo
Prazos de troca e garantia	Dependem da data de recebimento, aproximada pela previsão de entrega (S2)	Registrar a entrega efetiva no sistema de pedidos
Feriados	O cálculo de loja aberta os ignora (S8)	Calendário nacional, de Mato Grosso do Sul e de Campo Grande pela biblioteca `holidays`
Frete para outras cidades	O agente informa modalidades e prazos, mas não valores	Integração com tabela de fretes por CEP
Encaminhamento a humanos	Gravado em arquivo local	Integração com ferramenta de tickets ou com o WhatsApp da loja
Interface web	Sem autenticação nem limite de requisições, com escuta restrita ao endereço local; um turno por vez em cada sessão	Autenticação, limite de requisições e fila de turnos para uso em rede
Verificação de identidade	Número do pedido com e-mail ou telefone, verificação fraca aceitável para um protótipo	Número de WhatsApp autenticado ou código de uso único
Afirmações qualitativas	O verificador automático cobre valores monetários; afirmações sobre disponibilidade dependem do prompt e da avaliação	Verificação estruturada da resposta contra os resultados das ferramentas
Viés da avaliação	Casos escritos pelo próprio autor, que conhecia as armadilhas dos dados	Casos coletados de atendimentos reais e avaliação de tom por um modelo juiz
Observabilidade	Sem rastreamento estruturado das execuções	Traces com OpenTelemetry ou Langfuse, com latência e falhas por ferramenta
Recuperação	Adequada ao corpus atual	Critérios de evolução descritos na seção 4

Limitação	Situação atual	Encaminhamento com mais tempo
Latência	Com o modelo padrão, 14 s por turno em mediana e até 36 s no percentil 95, no hardware de desenvolvimento (seção 6.1); aceitável para um protótipo, longa para um atendimento real	Modelo menor ou provedor remoto para as perguntas simples, mantendo o modelo atual para pedidos e reclamações
Variação do modelo	O Qwen3-14B oscila entre execuções: respostas ocasionalmente incompletas (por exemplo, sem a data da garantia ou sem o status de envio) e, com raciocínio ligado, às vezes sem consultar a ferramenta. Também há ofertas fora do que a loja vende, como "ajuda para escolher acessórios" ao final de uma resposta de preço. Cada guardrail corrige uma única vez por turno	Amostragem repetida na avaliação, com taxa de aprovação por caso, e verificação de completude por tipo de pergunta
Pergunta sobre troca tratada como reclamação	Perguntas como "produto com defeito, como funciona a troca?" às vezes são encaminhadas a um atendente em vez de respondidas pelas políticas (caso pol-03)	Classificar a intenção em etapa própria, antes da escolha de ferramentas, ou exemplos no prompt
Critérios de avaliação	A comparação é lexical, o que gera falsos negativos com respostas corretas e exigiu ampliar três critérios (seção 6.2)	Avaliação semântica por um modelo juiz, validada contra uma amostra anotada à mão

9. Uso de assistentes de código

O projeto foi desenvolvido com o Claude Code, no aplicativo desktop, segundo a prática de desenvolvimento orientado a especificação (spec-driven development), em duas fases com configurações distintas.

Na fase de concepção, utilizou-se o modelo Claude Opus 5.5 com esforço de raciocínio extra alto. Nessa fase, o assistente leu o enunciado, o manual e os dados, executou a inspeção exploratória que revelou as inconsistências da seção 5 e, a partir da discussão das alternativas com o autor, redigiu a especificação em ARCHITECTURE.md. A especificação descreve decisões, regras de negócio com exemplos numéricos, contratos das ferramentas e dez etapas de implementação (E0 a E9), cada uma com tarefas, critérios de aceite e mensagem de commit. Na mesma fase foi criado um painel de acompanhamento, publicado como Artifact do Claude, que exibe cada etapa com o trecho da especificação que a define, suas tarefas e seu estado. O painel é atualizado tanto manualmente quanto pelas próprias sessões do assistente, e o script `scripts/painel_payload.py` mantém o conteúdo do painel sincronizado com o arquivo de especificação.

Na fase de implementação, cada etapa foi executada pelo modelo Claude Sonnet 5.5 com esforço alto, tendo a especificação como contrato e os critérios de aceite como condição de conclusão. A divisão reservou o modelo de maior capacidade para o momento em que erros custam mais caro, a definição da arquitetura e a interpretação das regras, e empregou um modelo mais rápido na execução de tarefas já delimitadas.

A etapa E8 foi acrescentada durante a implementação, por iniciativa do autor, para exercitar o produto pronto pela tela de chat com a skill `e2e-first-testing`, que orientou a escolha do Playwright, dos fluxos e do relatório. Essa etapa encontrou um defeito real, descrito na seção 6.3. Depois dela, a leitura das falhas da avaliação conduziu à criação de novos guardrails, e o autor pediu duas vezes que os casos reprovados fossem revistos antes da entrega, o que revelou, por exemplo, um protocolo de atendimento inventado

pelo modelo (seção 6.2). Em todas as execuções, o autor aprovou cada envio ao repositório antes de ele ocorrer.

As decisões de produto couberam ao autor, entre elas a persona roqueira, o formato da interface e a exclusão de grafos de conhecimento, busca híbrida e reranker. Coube ao assistente propor alternativas, apontar riscos e executar. A segurança do repositório foi verificada com a skill de auditoria `github-security-audit` antes da criação do repositório público, antes do primeiro envio de código e na entrega final.